

Modelo predicción hidrometeorológica para el Gobierno Regional de Piura

Hydro-meteorological prediction model for the Regional Government of Piura

Arteaga Abraham Castro Yuval Mamani Yudith Soto Franklin
019201420c@uandina.edu.pe 017100155i@uandina.edu.pe 019201447c@uandina.edu.pe 016101525e@uandina.edu.pe

Abstract—El proyecto de modelo predicción hidrometeorológica para el gobierno regional de Piura se centra en poder averiguar la forma en la que podemos predecir cuando el río, lago, ribera, presa puede contener un caudal fuerte o un caudal de donde se deba tomar precauciones. Todos los días se toma el caudal del río haciendo un monitoreo diario a través de la empresa meteorológica donde pasan estos ríos, lagos o presas. también se toma en cuanto los datos más importantes que son estos caudal a las 7:00 horas, Promedio del caudal en 24H. máximo caudal tomado en 24H, y la precipitación alrededor de las 24H. se entrenó el modelo usando RNN que se encarga de almacenar los los datos y mantener un control del caudal del agua evitando desbordamientos a través de el entrenamiento basado en RNN, con el entrenamiento se logra sacar el promedio caudal, promedio caudal a las 24H, máximo caudal 24H y la posible precipitación viendo el riesgo potencial de inundaciones o desbordamiento de agua.

Index Terms—Caudal, Presa, RNN, Hidrometeorológica

1. Introduction

La ciudad de Piura cuenta con su propia página de datos, en la cual cubre la mayoría de datos que tiene la ciudad dentro dentro de la página una parte de ese contenido son los datos hidrometeorológico de todos sus ríos, presas, lagos donde los que controlan su caudal son las estaciones hidrometeorológica. Cuando la empresa hidrometeorológica registra los datos, se sube los datos a la página donde se puede ver por día y mes la cantidad de caudal que tiene cada presa, río, lago que pueden controlar la empresa meteorológica, el propósito de investigación es poder controlar y poder identificar caudales peligrosos que pueden indicar desbordamiento o falta de agua en un río.

Junio 10, 2024




Figura 1: Datos Hidrometeorológicos - Servicios digitales Piura

2. Antecedentes

Antecedente 1.-Un estudio comparativo de arquitecturas de redes neuronales artificiales para la predicción de series temporales de datos de flujo en sistemas de distribución de agua: En este estudio comparativo, se evalúan varias arquitecturas de redes neuronales artificiales para la predicción de series temporales de flujo en la distribución de agua, en particular, mediante la exploración de la memoria temporal. Estos modelos incluyeron perceptrón multicapa, red de densidad de mezcla, red de retardo temporal y red recurrente. Además, se utilizó el ciclo diurno medio (calculado a partir del conjunto de datos) como una predicción de referencia. Se utilizaron dos conjuntos de datos de referencia como estudio de caso, originados en sistemas de distribución del mundo real, y el rendimiento se evaluó mediante el error absoluto medio

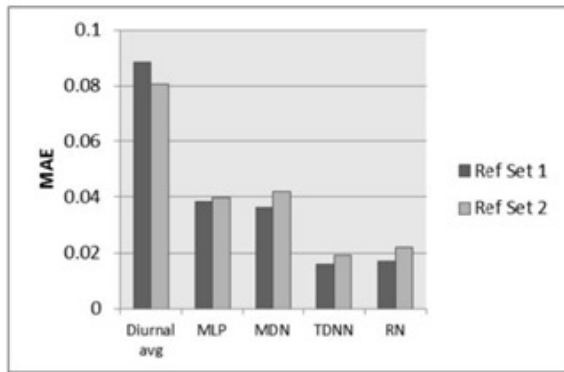


Figura 2: Figura de Steve Mounce desde ResearchGate - A comparative study of artificial neural network architectures for time series prediction of water distribution system flow data.

Antecedente 2.- En este estudio se midió el caudal de del agua mediante técnicas de aprendizaje automático basadas en árboles, concretamente Random Forest y XG Boost, así como técnicas de aprendizaje profundo, como LSTM bidireccional, convolucional 1D-BiLSTM y red neuronal recurrente. El rendimiento de los modelos se evaluó utilizando varios indicadores estadísticos como el error cuadrático medio (MSE), el índice de acuerdo (IA), el error cuadrático medio (RMSE), el error porcentual absoluto medio (MAPE), el error absoluto medio (MAE) y el error porcentual absoluto medio simétrico (SMAPE). Se observa que XGBoost, con el valor más bajo de RMSE de 0.0066 y la mayor precisión de 99.976, supera a todos los demás modelos.

Measures/Models	1-Conv1D-2-BiLSTM	2-Bidirectional LSTM	2-RNN	Random forest	XGBoost
IA	0.9971	0.9966	0.9966	0.9974	0.9977
MAE	0.0048	0.0055	0.0049	0.0045	0.0041
MAPE	0.4049	0.4638	0.4116	0.3831	0.3428
MSE	5.2816	6.4649	6.5345	4.9711	4.3509
RMSE	0.0073	0.0080	0.0081	0.0070	0.0066
SMAPE	0.0041	0.0046	0.0041	0.0038	0.0034
R-square	0.98	0.98	0.98	0.99	0.99
Training Accuracy	99.878	99.967	99.878	99.989	99.989
Testing Accuracy	99.867	99.867	99.867	99.956	99.976

Least RMSE values in machine learning and deep learning models (in bold)

Figura 4: Figura de IshanAyus, Narayanan Natarajan, Deepak Gupta - Prediction of Water Level Using Machine Learning and Deep Learning Techniques

3. Solución Planteada




Figura 3: Diagrama de pasos de la solución planteada

La solución se basa en las redes neuronales recurrentes (RNN) que son un tipo de red neuronal especialmente útil para procesar datos secuenciales o series temporales.

RNN es especialmente útil porque puede mantener información en "memoria" a través de sus conexiones recurrentes, lo que les permite aprender dependencias a largo plazo en los datos.

Al tener memoria a largo plazo cuando se carga una serie de datos, el modelo aprende de esos datos pudiendo comparar datos futuros, Para poder empezar debemos ver las consideraciones que

tenemos que tener para analizar los datos:

3.1. Datos de Entrada

Asegúrate de que las series temporales estén ordenadas cronológicamente antes de dividir los datos.

3.2. Hiper Parámetros

Experimenta con el número de capas, neuronas en cada capa y otros hiper parámetros para optimizar el rendimiento del modelo.

3.3. Validación Cruzada

Considera el uso de validación cruzada para evaluar la robustez del modelo.

3.4. Etapas del desarrollo del modelo

- 1) **Análisis exploratorio de datos (EDA):** la recolección de datos es el primer paso para empezar con RNN, donde los datos deben ser relevantes y fuentes confiables, para el proyecto se usará los datos que se proporcionan en la página de la municipalidad de Piura, después se debe corregir los datos y rellenar los datos nulos, se transforma los datos para poder estandarizar y normalizar los datos numéricos.
- 2) **Selección y creación de características:** Identificamos las variables más importantes para la predicción siendo las variables Caudal 70:00, Promedio 24H, Máxima 24H, Precipitación 24H.
- 3) **División de conjunto de datos:** Los datos se dividen en un 70% para el entrenamiento, 30 para la prueba, ya que también hay datos diarios, para la validación hay datos extras.
- 4) **Diseño y construcción de modelo:** Al inicio se usó un simple RNN con para que pueda captar las capas necesarias, después de varios intentos se llegó a usar Relu (parámetro definido automáticamente).

Luego de comparar distintas formas de configurar el modelo, se determinó un número de épocas de 108/150, alcanzando una precisión del 90%.




Figura 5: Fuente propia - Predicción con el mayor porcentaje con RNN.

Con un 90% de precisión podemos identificar el caudal de forma que se pueda identificar cuando el caudal es peligroso y se aproxima una precipitación.

4. Resultados

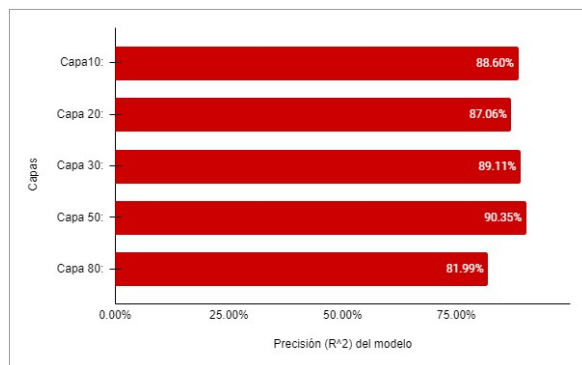


Figura 6: Fuente propia - Fuente propia - Predicción con el RNN dependiendo las capas

En esta figura se muestra las diferentes capas en un modelo de predicción. Se refleja en la tabla de resultados, la cual muestra el desempeño del modelo con diferentes configuraciones. Se observan cinco capas con los siguientes indicadores: R^2 , MSE, MAE y Precisión. La capa 50 destaca con el mayor R^2 (0.9035) y precisión (90.35%), indicando un excelente ajuste y predicción del modelo, además de un bajo error cuadrático medio (MSE) de 1591.0716 y un error absoluto medio (MAE) de 17.1832. En contraste, la capa 80 presenta el rendimiento más bajo con un R^2 de 0.8199 y una precisión del 81.99%, lo que sugiere que agregar demasiadas capas puede deteriorar el desempeño del modelo.

5. Conclusiones

La implementación de un modelo de predicción hidrometeorológica basado en RNN para el Gobierno Regional de Piura, ofrece una posible solución para anticipar situaciones de riesgo como inundaciones o desbordamientos. Al entrenar el modelo con datos esenciales, se obtiene una alerta temprana sobre posibles eventos adversos, permitiendo tomar medidas preventivas y reducir los impactos negativos.

La adopción de RNN en este contexto, demuestra su capacidad para analizar patrones temporales complejos y realizar predicciones precisas en condiciones hidrometeorológicas variables. Al enlazar el monitoreo continuo del caudal del agua con un modelo predictivo basado en RNN, el Gobierno Regional de Piura puede adaptar su capacidad de respuestas ante emergencias y fortalecer la gestión del riesgo de desastres relacionados con el agua.

References

- [1] M. Ríos-Martínez and S. Herrera, "Aplicación del Aprendizaje Profundo para la Predicción de Caudal Frente a Escenarios de Inundación del Río Arga," *Academia-e: Revista de Enseñanza e Investigación en Educación*, vol. 21, no. 2, pp. 379-404, 2020. <http://academica-e.unavarra.es/handle/2454/46538>
- [2] N. Rodríguez-Pérez and M. R. Salas-Jacobo, "Comparación de Pronósticos de Caudales Máximos con Modelos ARIMA y Redes Neuronales Artificiales," *Revista Científica de la Universidad Nacional José Faustino Sánchez Carrión*, vol. 20, no. 3, pp. 39-50, 2019. <https://revistas.unjbg.edu.pe/index.php/cs/article/download/988/1113>
- [3] G. A. Trapero Brizuela and J. D. Alvarez, "Predicción de Caudal Basados en Redes Neuronales Artificiales (RNA) para Períodos de Tiempo Sub Diarios," *Espacio, Tiempo y Forma*, vol. 21, no. 1, pp. 141-158, 2018. <http://dspace.ucuenca.edu.ec/bitstream/123456789/33276/1/documento.pdf>

- [4] M. López-Sande, J. A. Rodríguez-Díaz, and L. M. García-Díez, "Predicción de caudales en ríos mediante redes neuronales artificiales y sistemas neurodifusos," *Revista Internacional de Tecnologías de la Información y Comunicaciones*, vol. 11, no. 1, pp. 43-56, 2016. https://rcs.cic.ipn.mx/2016_113/Prediccion%20de%20caudales%20medios%20diarios%20en%20la%20cuenca%20del%20Amazonas%20aplicando%20redes%20neuronales.pdf
- [5] R. C. Paiva and A. F. Almeida, "Using artificial neural networks for short-term streamflow forecasting," *Journal of Hydrology*, vol. 518, pp. 24-38, 2014. <https://www.sciencedirect.com/science/article/pii/S002216949800242X>