

**Antecedente 1.-Un estudio comparativo de arquitecturas de redes neuronales artificiales para la predicción de series temporales de datos de flujo en sistemas de distribución de agua:** En este estudio comparativo, se evalúan varias arquitecturas de redes neuronales artificiales para la predicción de series temporales de flujo en la distribución de agua, en particular, mediante la exploración de la memoria temporal. Estos modelos incluyeron perceptrón multicapa, red de densidad de mezcla, red de retardo temporal y red recurrente. Además, se utilizó el ciclo diurno medio (calculado a partir del conjunto de datos) como una predicción de referencia. Se utilizaron dos conjuntos de datos de referencia como estudio de caso, originados en sistemas de distribución del mundo real, y el rendimiento se evaluó mediante el error absoluto medio

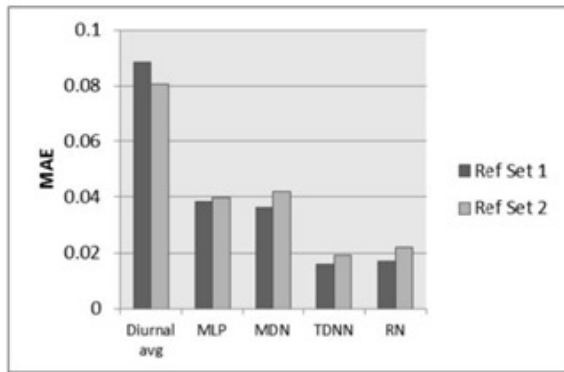


Figura 2: Figura de Steve Mounce desde ResearchGate - A comparative study of artificial neural network architectures for time series prediction of water distribution system flow data.

Antecedente 2.- En este estudio se midió el caudal de del agua mediante técnicas de aprendizaje automático basadas en árboles, concretamente Random Forest y XG Boost, así como técnicas de aprendizaje profundo, como LSTM bidireccional, convolucional 1D-BiLSTM y red neuronal recurrente. El rendimiento de los modelos se evaluó utilizando varios indicadores estadísticos como el error cuadrático medio (MSE), el índice de acuerdo (IA), el error cuadrático medio (RMSE), el error porcentual absoluto medio (MAPE), el error absoluto medio (MAE) y el error porcentual absoluto medio simétrico (SMAPE). Se observa que XGBoost, con el valor más bajo de RMSE de 0.0066 y la mayor precisión de 99.976, supera a todos los demás modelos.

Measures/Models	1-Conv1D-2-BiLSTM	2-Bidirectional LSTM	2-RNN	Random forest	XGBoost
IA	0.9971	0.9966	0.9966	0.9974	0.9977
MAE	0.0048	0.0055	0.0049	0.0045	0.0041
MAPE	0.4049	0.4638	0.4116	0.3831	0.3428
MSE	5.2816	6.4649	6.5345	4.9711	4.3509
RMSE	<b>0.0073</b>	0.0080	0.0081	0.0070	<b>0.0066</b>
SMAPE	0.0041	0.0046	0.0041	0.0038	0.0034
R-square	0.98	0.98	0.98	0.99	0.99
Training Accuracy	99.878	99.967	99.878	99.989	99.989
Testing Accuracy	99.867	99.867	99.867	99.956	99.976

Least RMSE values in machine learning and deep learning models (in bold)

Figura 4: Figura de IshanAyus, Narayanan Natarajan, Deepak Gupta - Prediction of Water Level Using Machine Learning and Deep Learning Techniques

### 3. Solución Planteada




Figura 3: Diagrama de pasos de la solución planteada

La solución se basa en las redes neuronales recurrentes (RNN) que son un tipo de red neuronal especialmente útil para procesar datos secuenciales o series temporales. RNN es especialmente útil porque puede mantener información en "memoria" a través de sus conexiones recurrentes, lo que les permite aprender dependencias a largo plazo en los datos. Al tener memoria a largo plazo cuando se carga una serie de datos, el modelo aprende de esos datos pudiendo comparar datos futuros, Para poder empezar debemos ver las consideraciones que

tenemos que tener para analizar los datos:

#### 3.1. Datos de Entrada

Asegúrate de que las series temporales estén ordenadas cronológicamente antes de dividir los datos.

#### 3.2. Hiper Parámetros

Experimenta con el número de capas, neuronas en cada capa y otros hiper parámetros para optimizar el rendimiento del modelo.

#### 3.3. Validación Cruzada

Considera el uso de validación cruzada para evaluar la robustez del modelo.

#### 3.4. Etapas del desarrollo del modelo

- 1) **Análisis exploratorio de datos (EDA):** la recolección de datos es el primer paso para empezar con RNN, donde los datos deben ser relevantes y fuentes confiables, para el proyecto se usará los datos que se proporcionan en la página de la municipalidad de Piura, después se debe corregir los datos y rellenar los datos nulos, se transforma los datos para poder estandarizar y normalizar los datos numéricos.
- 2) **Selección y creación de características:** Identificamos las variables más importantes para la predicción siendo las variables Caudal 70:00, Promedio 24H, Máxima 24H, Precipitación 24H.
- 3) **División de conjunto de datos:** Los datos se dividen en un 70% para el entrenamiento, 30 para la prueba, ya que también hay datos diarios, para la validación hay datos extras.
- 4) **Diseño y construcción de modelo:** Al inicio se usó un simple RNN con para que pueda captar las capas necesarias, después de varios intentos se llegó a usar Relu (parámetro definido automáticamente).

Luego de comparar distintas formas de configurar el modelo, se determinó un número de épocas de 108/150, alcanzando una precisión del 90%.




Figura 5: Fuente propia - Predicción con el mayor porcentaje con RNN.

Con un 90% de precisión podemos identificar el caudal de forma que se pueda identificar cuando el caudal es peligroso y se aproxima una precipitación.

### 4. Resultados

Nuestros resultados indican que las Redes Neuronales Recurrentes (RNN) destacan en la precisión de la predicción de series

temporales. Se presentan gráficos comparativos entre las predicciones de RNN y los valores reales, reforzando esta observación. Además, a través de mejoras en las tablas de origen, se logró mejorar la precisión de las predicciones. Con un coeficiente de determinación del 90.47%, un MSE de 1571.59 y un MAE de 13.96, la RNN demostró su capacidad para capturar la variabilidad de los datos y producir predicciones precisas. Estos resultados apuntan a la efectividad de la RNN en aplicaciones de predicción de series temporales.

## 5. Conclusiones

La implementación de un modelo de predicción hidrometeorológica basado en RNN para el Gobierno Regional de Piura, ofrece una posible solución para anticipar situaciones de riesgo como inundaciones o desbordamientos. Al entrenar el modelo con datos esenciales, se obtiene una alerta temprana sobre posibles eventos adversos, permitiendo tomar medidas preventivas y reducir los impactos negativos.

La adopción de RNN en este contexto, demuestra su capacidad para analizar patrones temporales complejos y realizar predicciones precisas en condiciones hidrometeorológicas variables. Al enlazar el monitoreo continuo del caudal del agua con un modelo predictivo basado en RNN, el Gobierno Regional de Piura puede adaptar su capacidad de respuestas ante emergencias y fortalecer la gestión del riesgo de desastres relacionados con el agua.

## References

- [1] M. Ríos-Martínez and S. Herrera, "Aplicación del Aprendizaje Profundo para la Predicción de Caudal Frente a Escenarios de Inundación del Río Arga," *Academia-e: Revista de Enseñanza e Investigación en Educación*, vol. 21, no. 2, pp. 379-404, 2020. <http://academica-e.unavarra.es/handle/2454/46538>
- [2] N. Rodríguez-Pérez and M. R. Salas-Jacobo, "Comparación de Pronósticos de Caudales Máximos con Modelos ARIMA y Redes Neuronales Artificiales," *Revista Científica de la Universidad Nacional José Faustino Sánchez Carrión*, vol. 20, no. 3, pp. 39-50, 2019. <https://revistas.unjbg.edu.pe/index.php/cs/article/download/988/1113>
- [3] G. A. Trapero Brizuela and J. D. Alvarez, "Predicción de Caudal Basados en Redes Neuronales Artificiales (RNA) para Períodos de Tiempo Sub Diarios," *Espacio, Tiempo y Forma*, vol. 21, no. 1, pp. 141-158, 2018. <http://dspace.ucuenca.edu.ec/bitstream/123456789/33276/1/documento.pdf>
- [4] M. López-Sande, J. A. Rodríguez-Díaz, and L. M. García-Díez, "Predicción de caudales en ríos mediante redes neuronales artificiales y sistemas neurodifusos," *Revista Internacional de Tecnologías de la Información y Comunicaciones*, vol. 11, no. 1, pp. 43-56, 2016. [https://rcs.cic.ipn.mx/2016\\_113/Prediccion%20de%20caudales%20medios%20diarios%20en%20la%20cuenca%20del%20Amazonas%20aplicando%20redes%20neuronales.pdf](https://rcs.cic.ipn.mx/2016_113/Prediccion%20de%20caudales%20medios%20diarios%20en%20la%20cuenca%20del%20Amazonas%20aplicando%20redes%20neuronales.pdf)
- [5] R. C. Paiva and A. F. Almeida, "Using artificial neural networks for short-term streamflow forecasting," *Journal of Hydrology*, vol. 518, pp. 24-38, 2014. <https://www.sciencedirect.com/science/article/pii/S002216949800242X>